

Classificação Incremental e Auditável de Crimes em Notícias Institucionais com Memória WNN e LLM Residual

Jefferson S. dos Anjos

Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ)

Rio de Janeiro, RJ, Brasil

jefferson.anjos.1@aluno.cefet-rj.br

Resumo—Bases textuais institucionais crescem continuamente e tornam custosa a classificação temática, a revisão humana e, sobretudo, o envio indiscriminado de tokens a modelos de linguagem. Este trabalho propõe uma metodologia incremental e auditável para classificar o crime canônico principal em notícias públicas da Polícia Federal. A abordagem combina fundação temporal, memória lexical binária inspirada em WNN/WiSARD e revisão residual por LLM. Na rodada concluída, a memória classificou diretamente 53,48% da reserva, evitando igual proporção de chamadas e restringindo a LLM aos 46,52% de casos residuais. Contra as tags institucionais mapeadas após a decisão, a WNN obteve precisão de 85,29%, revocação de 49,91% e medida-F1 de 62,97%. Os resultados preservam evidências lexicais, versões da memória e decisões residuais para auditoria.

Index Terms—classificação textual, aprendizado incremental, redes neurais sem pesos, WiSARD, auditoria, modelo de linguagem

I. INTRODUÇÃO

Instituições públicas que produzem ou analisam informação em larga escala lidam continuamente com grandes volumes de textos. Notícias, registros administrativos, documentos técnicos e comunicados institucionais acumulam evidências relevantes para a análise de políticas públicas, mas nem sempre estão organizados em categorias estáveis. O desafio, portanto, não se limita ao armazenamento dos documentos: consiste em transformar um fluxo textual contínuo em informação temática comparável, auditável e reutilizável.

Esse processo é dificultado pela heterogeneidade da base, pelo seu crescimento ao longo do tempo e pela coexistência de fenômenos recorrentes e emergentes. A variação lexical, as mudanças de enfoque e a presença de atributos acidentais — como localidades, nomes de operações e entidades — podem induzir categorias artificiais. Embora a rotulagem humana seja onerosa e pouco escalável, uma classificação automática sem controles pode reproduzir ruídos, transformar metadados em classes e comprometer a estabilidade da taxonomia.

Modelos de linguagem de grande porte podem apoiar a interpretação de textos, mas enviar toda a base à API transforma cada notícia em consumo recorrente de tokens e custo de inferência. Este trabalho explora uma divisão de responsabilidades: a memória WNN trata documentos recorrentes com evidência lexical suficiente, sem chamada à LLM; a LLM revisa somente casos residuais, ambíguos ou semanticamente

inéditos. Os aprendizados validados podem então ser incorporados à memória como marcadores auditáveis, ampliando gradualmente a parcela atendida sem consumo de tokens pela API.

Assim, o objetivo é responder à seguinte questão: *como organizar e classificar incrementalmente uma base textual institucional em crescimento, reduzindo o custo de inferência por LLM e preservando auditabilidade, adaptação a novos temas e estabilidade da taxonomia?* A metodologia é aplicada a notícias públicas da Polícia Federal e tem como alvo o crime canônico principal de cada documento. Sua contribuição é propor um ciclo reproduzível de fundação temática, classificação incremental, revisão residual e atualização controlada da memória, e não apenas uma classificação pontual da base analisada.

II. TRABALHOS RELACIONADOS

Rangel et al. [1] exploram uma WiSARD semissupervisionada para textos e evidenciam a rapidez de treinamento e o aprendizado incremental de redes sem pesos. Carneiro [2] discute a robustez do *bleaching* e a influência da representação de entrada. Esses estudos sustentam a retina textual e o uso de confiança, mas tratam classes predefinidas ou etiquetas linguísticas; não abordam a consolidação temporal de uma taxonomia de crimes nem o encaminhamento seletivo para LLM.

Snorkel e ontologias especializadas usam regras interpretáveis para gerar supervisão programática [3]–[6]. LDA, BER-Topic, HDBSCAN e Sentence-BERT apoiam descoberta de tópicos, agrupamento e proximidade semântica [7]–[10]. Nesta proposta, clusters apoiam apenas a fundação: cada agrupamento precisa ser consolidado como crime canônico, e os discriminadores permanecem como memória operacional versionada, não apenas como sinais para treinar outro modelo.

LLMs podem gerar funções de rotulagem, interpretar textos e refinar regras [11]–[14]. O roteamento sensível à confiança também busca reduzir custo de inferência [15]. A diferença é que a proposta não escolhe entre LLMs: evita chamadas para notícias recorrentes mediante memória lexical e reserva uma única LLM para resíduos. A atualização de classes e taxonomias [16]–[18] e o *bootstrapping* de padrões [19] complementam esse ciclo. Assim, a contribuição é integrar funda-

ção temporal, memória WNN, revisão residual e atualização auditável em uma base institucional em evolução.

III. METODOLOGIA

A. Visão geral

Propõe-se uma metodologia incremental para classificar notícias institucionais pelo crime canônico principal. A base completa é ordenada pela data de publicação e dividida por um corte cronológico em duas partes disjuntas: a fundação contém os 10% mais antigos dos documentos, e a reserva incremental contém os 90% posteriores. A fundação é usada para descobrir e consolidar a taxonomia inicial sem acesso a documentos futuros; a reserva é processada em lotes cronológicos de 500 notícias para avaliar a cobertura da memória WNN, os encaminhamentos residuais, a evolução temporal dos crimes e o aprendizado controlado de novos marcadores.

O corpo da notícia é a única fonte textual da classificação, pois descreve o fato jurídico e suas evidências. Título e tags são preservados para auditoria e avaliação. Em particular, as tags não participam da construção da retina, da ativação de discriminadores nem da decisão da WNN ou da revisão residual por LLM; são consultadas somente após essa decisão, em uma etapa determinística de validação do aprendizado.

A memória adotada é uma implementação lexical binária inspirada em princípios de WNN/WiSARD, e não uma reprodução da WiSARD clássica. Em particular, ela não emprega o mapeamento pseudoaleatório da retina para um conjunto de RAMs endereçáveis. A implementação associa posições lexicais estáveis a discriminadores de crime, constrói vetores binários para os documentos e decide por pontuação de máscaras, cobertura, confiança e margem. A inspiração nas redes neurais sem pesos orienta a representação e a atualização incremental, enquanto as regras de decisão são explicitadas e auditadas no domínio textual.

B. Variáveis da notícia e política de uso

Cada notícia é representada por quatro variáveis. A Tabela I delimita seu papel para impedir vazamento de rótulos e confusão entre metadados e evidência classificatória.

Tabela I
VARIÁVEIS DA NOTÍCIA E SEUS USOS NO FLUXO.

Variável	Uso operacional
$x_1 = \text{titulo}$	Metadado preservado para identificação e auditoria; não entra na retina.
$x_2 = \text{tags}$	Referência publicada, mapeada após a decisão; avalia a classificação e autoriza o aprendizado residual. Não entra na retina, WNN ou LLM.
$x_3 = \text{texto_noticia}$	Corpo da notícia; única entrada textual da retina e da classificação.
$x_4 = \text{data_noticia}$	Ordena cronologicamente a base e define fundação e reserva; não entra na retina.

Assim, x_4 permite separar os 10% históricos da fundação dos 90% posteriores da reserva sem acesso a documentos futuros. A classificação de uma notícia usa exclusivamente x_3 , enquanto x_2 só é consultado depois da decisão para medir sua concordância com a taxonomia institucional publicada e validar a incorporação de aprendizado residual.

C. Retina textual, vocabulário e decisão

O fluxo da retina textual é: *texto_noticia* → normalização e pré-processamento linguístico → tokens e expressões de domínio → vocabulário versionado de posições estáveis → vetor binário → máscaras dos discriminadores → pontuação, confiança e margem → crime principal, marcadores secundários ou abstenção. Portanto, a retina não codifica título, tags, data, localidades ou outros metadados externos ao corpo da notícia.

Para evitar ambiguidade com a terminologia original da WiSARD, este trabalho utiliza os termos apresentados na Tabela II.

Tabela II
NOMENCLATURA DA MEMÓRIA WNN APLICADA A TEXTOS.

Termo	Definição operacional
Texto semântico	Representação pré-processada do corpo da notícia, com remoção de ruído e retenção de termos substantivos relevantes.
Retina textual	Camada de codificação que projeta o texto semântico em um vetor binário de posições lexicais fixas. O termo é usado por analogia à retina da WiSARD; não se refere a imagem.
Vocabulário versionado	Sequência ordenada $V^{(t)} = (a_1, a_2, \dots, a_{n_t})$ de posições lexicais normalizadas na versão t da memória.
Posição lexical a_i	Índice estável associado a uma palavra discriminativa normalizada, por exemplo, $a_{12} = \text{cartao}$.
Vetor binário da notícia	Vetor $\mathbf{x}(d)$ que indica quais posições do vocabulário foram ativadas pelo documento d .
Máscara de crime	Vetor binário contínuo associado a um crime canônico, indicando as posições lexicais que fundamentam sua identificação.
Imagem binária ou cartão perfurado	Representação visual da máscara ou do vetor da notícia. As quebras em linhas servem apenas para caber no espaço da figura; não representam novas dimensões nem novas classes.
Discriminador	Conjunto pequeno de posições e termos que, quando ativados em combinação, fornece evidência para uma máscara de crime.

Seja $V^{(t)} = (a_1, a_2, \dots, a_{n_t})$ o vocabulário versionado na iteração t . Para uma notícia d , a retina textual produz o vetor binário

$$x_i(d) = \begin{cases} 1, & \text{se o termo associado a } a_i \text{ ocorre em } d; \\ 0, & \text{caso contrário.} \end{cases} \quad (1)$$

Logo, $\mathbf{x}(d) \in \{0, 1\}^{n_t}$. Cada crime canônico c possui uma máscara binária contínua

$$\mathbf{m}_c^{(t)} = (m_{c1}, m_{c2}, \dots, m_{cn_t}) \in \{0, 1\}^{n_t}, \quad (2)$$

em que $m_{ci} = 1$ indica que a posição a_i fundamenta o crime c , e $m_{ci} = 0$ indica ausência dessa associação. Inspirada na retina binária e nos discriminadores RAM da WiSARD [1], [2], a memória é apresentada como cartões perfurados: cada cartão visualiza a máscara binária de um crime sobre o mesmo vocabulário versionado. Essa é uma visualização interpretável

proposta neste trabalho; não substitui a arquitetura RAM clássica. Uma nova linha exibida na grade representa somente a continuação do vetor na linha seguinte.

Por exemplo, se $a_{12} = \text{cartao}$, $a_{31} = \text{perfurado}$ e $a_{44} = \text{fraude}$, a máscara de um crime financeiro terá valor 1 nessas posições. A expressão *cartão perfurado* não exige uma posição adicional: ela é representada pela ativação conjunta de a_{12} e a_{31} .

A Figura 1 ilustra a construção de discriminadores para o crime *armas_municoes*. O vocabulário ocupa posições estáveis na retina textual; o documento ativa as posições correspondentes às palavras observadas; e cada discriminador é uma combinação de posições que fornece evidência para a máscara do crime. O exemplo é didático e apresenta apenas dez posições; ao final da execução, a memória WNN continha 403 posições lexicais versionadas. Os cartões perfurados simplificados da figura mostram que cada crime ocupa um padrão distinto sobre as mesmas posições; eles não representam a quantidade total de bits nem os padrões completos da memória.




Figura 1. Exemplo didático de vetor binário, ativação de discriminadores e cartões perfurados simplificados das máscaras de crime.

Uma coincidência parcial não é suficiente para considerar um discriminador integralmente ativado. No exemplo, a ocorrência de *fuzil* e *carregadores* ativa apenas parte das posições de d_2 , pois o trecho não contém *arsenal* nem *pistola*; por isso, d_2 não produz a mesma evidência de d_1 . Analogamente, como nenhuma palavra de d_3 ocorre no documento, esse discriminador permanece inativo. A decisão da memória considera a cobertura de cada discriminador e da máscara do crime, além da confiança e da margem entre classes, evitando que uma palavra isolada seja tomada como evidência conclusiva.

D. Fundação temática: 10% da base

A fundação temática executa duas funções. A Função 1 consolida temas canônicos a partir dos clusters exploratórios. Inicialmente, os documentos são pré-processados, vetorizados e agrupados por HDBSCAN; em seguida, a similaridade do cosseno auxilia a aproximar clusters semanticamente equivalentes. A função interpreta os agrupamentos, controla atributos

acidentais — como localidades, órgãos e nomes de operações — e define crimes canônicos que representam o fenômeno substantivo predominante.

Na execução, o pré-processamento linguístico foi aplicado aos 8.600 documentos antes da fundação e da classificação incremental. A representação preservou substantivos, verbos, adjetivos e expressões de domínio, removendo 512.589 de 1.277.742 tokens originais (redução de 40,12%) e mantendo 765.153 tokens para as etapas analíticas.

A Função 2 gera discriminadores lexicais de crime. Para cada crime canônico, são selecionados marcadores substantivos e combinações de marcadores que compõem sua máscara vetorial WNN. A saída é um banco de discriminadores auditável, que registra o crime associado, os termos, as posições lexicais, a origem e o número de confirmações.

E. Funções e instruções operacionais

As funções do fluxo são definidas por contratos de entrada, instruções de operação e saídas estruturadas. Não se reproduzem os *prompts* integralmente, pois eles incluem dados da rodada, mas a Tabela III registra as instruções que delimitam as decisões e permitem reproduzir o procedimento.

Tabela III
FUNÇÕES, ENTRADAS E SAÍDAS AUDITÁVEIS.

Função	Entrada, decisão e saída
1. Consolidação temática	Resumos de clusters e termos de domínio; consolida crimes canônicos e ignora atributos acidentais. Retorna rótulo, evidências, confiança e decisão.
2. Geração de discriminadores	Crimes e evidências da fundação; cria combinações de termos substantivos. Retorna discriminadores com posições, peso e origem.
3. Classificação pela WNN	Recebe somente x_3 e a memória; calcula pontuação, cobertura, confiança e margem. Retorna crime, marcadores ou encaminhamento residual.
4. Revisão residual por LLM	Recebe x_3 , classes permitidas e evidências WNN; interpreta casos residuais. Retorna decisão, rótulo, confiança, evidência e marcadores.
5. Validação supervisionada	Recebe a saída residual, pontuações WNN e x_2 mapeado; confirma, corrige ou bloqueia o aprendizado.

Após a revisão residual, um candidato não é promovido automaticamente. A governança compara suas evidências com as máscaras e os crimes já existentes; quando houver equivalência semântica, o caso é absorvido pela classe canônica correspondente. Por exemplo, ocorrências de pornografia infantil ou infantojuvenil são incorporadas a *crimes_contra_crianças*, e não criam uma nova categoria. Somente candidatos recorrentes, textualmente distintos e confirmados podem ampliar a taxonomia.

F. Classificação incremental: 90% da base

A Função 3 processa a reserva incremental em lotes. O corpo pré-processado de cada notícia é projetado pela retina textual no vetor $x(d)$ e comparado às máscaras de crime. De forma abstrata, a pontuação de um crime pode ser expressa por

$$S(c, d) = \sum_{i=1}^{n_t} m_{ci}^{(t)} x_i(d). \quad (3)$$

Na implementação, a pontuação considera as posições efetivamente ativadas, a cobertura da máscara, a confiança da decisão e sua margem em relação às alternativas. Padrões generalistas compartilhados entre crimes atuam somente como contexto; a decisão exige marcador específico. A notícia é aceita pela WNN quando os limiares de evidência, confiança e margem são atendidos, quando o tema líder possui evidência lexical suficiente e é confirmado pela similaridade do cosseno, ou quando essa similaridade desempata as duas classes líderes. A decisão aceita registra o crime canônico, os marcadores ativados, as posições binárias, a versão da memória e a origem das evidências.

Os limiares de confiança são ajustados dinamicamente por classe. Cada ajuste é limitado a dois pontos percentuais: com pelo menos 10 referências, o limiar diminui quando a precisão é de pelo menos 80% e a revocação é inferior a 30%, aumentando a cobertura; quando a precisão é inferior a 80%, ele aumenta para reduzir falsos positivos. Os valores permanecem limitados a 35–70% nas classes usuais e a 60–80% em *crime_organizado*. As margens específicas são preservadas.

O tratamento de decisões pouco separadas inspira-se conceitualmente no *bleaching* da WiSARD [2]. Na técnica original, o limiar de resposta é ajustado para distinguir discriminadores empatados ou muito próximos. Nesta proposta, o mecanismo não implementa *bleaching* nas RAMs: quando a maior pontuação não apresenta margem ou confiança suficiente, a Função 4 encaminha a notícia à LLM para uma revisão contextual. Posteriormente, a Função 5 pode aplicar uma desambiguação supervisionada análoga ao princípio de separação: ela restringe a comparação aos crimes indicados por x_2 , mas seleciona o crime principal somente pelas pontuações textuais já calculadas pela WNN. Assim, as tags delimitam candidatos válidos, sem se tornarem entrada da retina ou da LLM.

G. Revisão residual e atualização controlada

A Função 4 revisa exclusivamente documentos residuais, ambíguos ou semanticamente inéditos. A revisão contextual pode confirmar um crime canônico, registrar uma notícia rara ou propor um tema candidato. Ela não substitui a memória WNN para os documentos já aceitos com evidência suficiente.

A Função 5, denominada Agente 4, executa a validação supervisionada pós-decisão. Quando a classe proposta pela LLM coincide com ao menos uma tag criminal mapeada, o aprendizado é confirmado. Quando existe uma única referência e ocorre divergência, o rótulo associado aos novos discriminadores é corrigido para essa referência, preservando-se a resposta original da LLM para auditoria. Quando há múltiplas referências divergentes, o Agente 4 ordena apenas essas classes pelas pontuações WNN já registradas. O aprendizado é autorizado se a classe líder apresentar evidência forte e margem configurada sobre a segunda colocada; a classe escolhida torna-se o crime

principal e as demais permanecem como marcadores secundários. Em particular, *crime_organizado* é tratado como marcador pai estrutural: um delito concreto, como tráfico, lavagem ou contrabando, preserva a decisão principal, e a evidência explícita de organização criminosa acrescenta o pai como marcador secundário. Na ausência dessa separação, a atualização é bloqueada e a divergência é registrada. A Figura 2 sintetiza esse fluxo de atualização controlada.




Figura 2. Atualização supervisionada da memória após revisão residual. O Agente 3 interpreta exclusivamente o corpo da notícia (x_3). O Agente 4 consulta x_2 somente após a decisão para confirmar, corrigir ou bloquear a atualização da memória WNN.

O crescimento da memória é controlado por uma política de vocabulário imutável e expansível por acréscimo. Uma posição já existente mantém seu significado e seu índice durante toda a execução. Antes de criar uma posição, o sistema normaliza o termo e consulta o mapa $termo \rightarrow a_i$. Se o termo já existir, sua posição é reutilizada; se a evidência corresponder apenas a uma combinação de termos existentes, a máscara do crime é atualizada sem expandir o vocabulário.

Uma palavra inédita sugerida pela revisão residual é registrada inicialmente como variante pendente. Ela só é admitida como nova posição a_{n_t+1} após pelo menos duas confirmações recorrentes. Quando aprovada, a nova posição é acrescentada no final de $V^{(t)}$, sem reordenar as posições anteriores. Assim, vetores históricos permanecem comparáveis mediante preenchimento de zeros à direita. A criação de um novo crime adiciona uma nova máscara vetorial sobre o vocabulário existente; ela não exige, necessariamente, uma nova posição lexical.

Ao término da execução, o organizador da árvore aplica uma realimentação métrica conservadora ao banco de discriminadores. Para cada decisão autônoma já registrada, ele consulta x_2 somente após a classificação e identifica as máscaras completas que contribuíram para o rótulo aceito. Uma ativação concordante incrementa a confirmação do discriminador. Um padrão aprendido ou generalizado é colocado em quarentena somente quando acumula pelo menos duas ativações incorretas e nenhuma ativação correta; discriminadores curados não são desativados automaticamente. Antes de qualquer atualização,

o banco é versionado em *snapshot*, e a decisão de reforço ou quarentena é registrada para auditoria. Esse procedimento ajusta a memória para execuções futuras, sem alterar retrospectivamente a decisão usada para calcular as métricas do lote.

H. Avaliação e auditabilidade

A avaliação operacional mede a cobertura da WNN, a taxa de encaminhamento residual, o consumo de tokens pela LLM, a quantidade de discriminadores confirmados, os candidatos a novos temas e a evolução do vocabulário. Após cada decisão, as tags x_2 são mapeadas para crimes canônicos e usadas para calcular precisão, revocação, medida-F1 e matriz de confusão. A métrica global considera a decisão principal; a métrica por classe considera também marcadores secundários estruturais, para contabilizar a relação pai-filha de *crime_organizado* sem fazê-lo competir com o delito concreto. No ramo residual, as tags também permitem ao Agente 4 validar a classe sob a qual um discriminador será incorporado. Tanto a avaliação quanto a validação ocorrem após as decisões da WNN e da LLM; portanto, x_2 não é entrada da retina nem do *prompt* da revisão residual e não substitui uma anotação independente por especialistas.

Cada execução preserva as máscaras vetoriais dos crimes, o vocabulário versionado, os vetores e posições ativadas, as decisões residuais, as alterações de taxonomia e os relatórios de realimentação métrica. Esses artefatos permitem reconstruir a justificativa de uma classificação, verificar quando uma posição ou máscara foi incorporada à memória e identificar quais padrões foram reforçados ou colocados em quarentena.

IV. RESULTADOS

Esta seção apresenta os diagnósticos operacionais da rodada concluída. A unidade experimental foi a notícia pública da Polícia Federal. A base reuniu 8.600 documentos, dos quais os 860 (10%) mais antigos compuseram a fundação temática e os 7.740 (90%) posteriores formaram a reserva incremental. Temporalmente, a fundação compreendeu notícias de 29/11/2011 até 30/08/2020; a reserva iniciou em 30/08/2020 e foi processada sem reordenamento cronológico em 16 lotes, quinze com 500 notícias e o último com 240. A coincidência da data de corte ocorre porque há múltiplas notícias publicadas em 30/08/2020; a ordem original do manifesto define a separação entre fundação e reserva nessa data.

A. Fundação e evolução da taxonomia

Na fundação de 860 notícias, TF-IDF produziu 12.675 termos e 98.381 valores não nulos. O *MiniBatch K-Means*, usado como *fallback*, produziu 29 clusters brutos (silhueta de 0,302837), consolidados em 20 para interpretação temática. A fundação resultou em 17 crimes canônicos. Na reserva, o organizador avaliou 197 candidatos, absorveu 191 em temas existentes e promoveu três temas operacionais. A recorrência de pornografia infantil permanece vinculada a *crimes_contra_crianças*; assim, temas operacionais não alteram retroativamente os rótulos avaliados pela WNN.

B. Cobertura da memória e encaminhamento residual

O principal indicador operacional é a cobertura da memória WNN: a proporção de documentos da reserva classificados pela camada determinística antes de qualquer revisão por LLM. A Tabela IV sintetiza os indicadores acumulados. A WNN classificou diretamente 4.139 das 7.740 notícias da reserva, atingindo cobertura operacional de 53,48%. Os 3.601 documentos restantes foram registrados como residuais e demandaram revisão contextual por LLM. Para avaliar a qualidade das decisões WNN, as tags x_2 foram mapeadas após a classificação: entre 2.312 notícias com referência criminal mapeada, houve 1.353 classificações WNN e 1.154 predições corretas.

Tabela IV
DIAGNÓSTICOS ACUMULADOS DA RODADA COM FUNDAÇÃO DE 10%.

Indicador	Valor
Notícias na base completa	8.600
Notícias na fundação temática	860
Notícias na reserva incremental	7.740
Período da fundação temporal	29/11/2011–30/08/2020
Início da reserva incremental	30/08/2020
Lotes processados	16
Notícias classificadas diretamente pela WNN	4.139
Cobertura operacional acumulada da WNN	53,48%
Documentos residuais pós-WNN	3.601
Chamadas residuais à LLM	3.601
Taxa de chamada à LLM	46,52%
Tokens consumidos nas chamadas residuais	7.398.441
Modelo da revisão residual	<i>gpt-4.1-mini</i>
Média de tokens por chamada residual	2.055
Notícias com referência x_2 criminal mapeada	2.312
Cobertura WNN no subconjunto com x_2	58,52%
Precisão WNN contra x_2	85,29%
Revocação WNN contra x_2	49,91%
Medida-F1 WNN contra x_2	62,97%

Esse resultado indica que a LLM não precisou ser aplicada à totalidade da reserva. Se fosse o classificador principal, haveria 7.740 chamadas; a memória evitou 4.139 (53,48%). A revisão residual consumiu 7.398.441 tokens pelo *gpt-4.1-mini*, ou 2.055 por chamada. Essa redução mede eficiência, não qualidade semântica; por isso, a tabela também apresenta as métricas contra x_2 .

C. Evolução da cobertura por lote

A cobertura não permaneceu constante ao longo da reserva temporal. Nos sete primeiros lotes, a WNN aceitou 1.539 das 3.500 notícias (43,97%); nos nove lotes seguintes, aceitou 2.600 das 4.240 notícias (61,32%). Assim, a segunda parte da execução encaminhou 1.640 notícias à LLM, mesmo contendo 740 documentos a mais que a primeira, que encaminhou 1.961. Essa diferença é compatível com o enriquecimento incremental e a calibração dos limiares, mas não demonstra causalidade isolada, pois a distribuição temática também varia no tempo.

D. Métricas por classe

A Tabela V contrasta classes críticas e classes com desempenho elevado. n é a quantidade de notícias com tag x_2 mapeada. A classe *crimes_sistema_financeiro* possui somente três referências; sua métrica é diagnóstica, não conclusiva. Para

Tabela V
DESEMPENHO DA WNN POR CLASSE CONTRA x_2 .

Classe	n	Prec.	Rev.	F1
crime_organizado	156	36,96%	10,90%	16,83%
crimes_sistema_financeiro	3	1,82%	33,33%	3,45%
armas_municoes	79	26,29%	58,23%	36,22%
corrupcao_desvio_recursos_publicos	209	53,85%	33,49%	41,30%
lavagem_dinheiro	257	49,07%	51,36%	50,19%
crimes_contra_crianças	535	98,16%	79,63%	87,93%
crimes_ambientais	222	87,57%	69,82%	77,69%
moeda_falsa	93	88,24%	80,65%	84,27%
trabalho_escravo	30	82,14%	76,67%	79,31%

crime_organizado, a métrica considera o marcador estrutural pai, sem substituir o delito concreto como decisão principal.

As classes com evidência lexical mais específica apresentam o comportamento esperado para a camada determinística. *Crimes_contra_crianças* alcançou precisão de 98,16% e medida-F1 de 87,93%; *moeda_falsa*, *trabalho_escravo* e *crimes_ambientais* também superaram 77% de F1. Esses resultados indicam que vocabulários recorrentes e especializados podem ser resolvidos pela WNN com pouca dependência de interpretação contextual.

Em contraste, *armas_municoes* obteve precisão de 26,29%, o que sugere ativações por contexto incidental, enquanto *crimes_sistema_financeiro* não permite conclusão devido ao suporte de apenas três referências. A classe-pai *crime_organizado* apresentou revocação de 10,90%, pois sua identificação exige evidência estrutural adicional e não é inferida automaticamente a partir de toda classe-filha. Já *corrupcao_desvio_recursos_publicos* e *lavagem_dinheiro* mantêm desempenho intermediário, compatível com a sobreposição lexical entre recursos, contratos, valores e ocultação. Esses casos justificam o encaminhamento residual e a revisão dos discriminadores, em vez da redução indiscriminada dos limiares.

E. Interpretação operacional e auditabilidade

Os documentos aceitos pela WNN preservam o crime canônico atribuído, os discriminadores ativados, as posições lexicais correspondentes, a versão da memória e a origem da evidência. Nos casos de baixa confiança, margem insuficiente ou competição entre máscaras, a decisão é deslocada para a revisão contextual da Função 4. Desse modo, os resultados permitem identificar tanto a parcela absorvida por evidência lexical recorrente quanto a parcela que exige interpretação adicional.

O Agente 4 avaliou os 3.601 documentos residuais: confirmou 798 decisões, corrigiu 144 e bloqueou 2.659 aprendizados automáticos por insuficiência de concordância com a referência pós-decisão. Ao longo da rodada, 923 regras foram incorporadas à memória e cinco discriminadores generalizados foram colocados em quarentena após falsos positivos sem ativações corretas. Esses registros distinguem a decisão histórica usada na métrica da atualização que afetará execuções futuras.

O uso dos diagnósticos de cobertura deve ser interpretado com cautela. Cobertura WNN não equivale a acurácia, pois a rodada não possui uma amostra de referência integralmente

validada por especialistas. As tags institucionais fornecem uma referência operacional publicada pela fonte, mas podem ser incompletas, multilabel ou adotar granularidade distinta da taxonomia canônica. Além disso, a comparação com execuções anteriores é apenas operacional, pois as rodadas diferem em base, fração amostral, fundação temática e parâmetros. Assim, os resultados sustentam a viabilidade do fluxo e a redução do acionamento de LLM, enquanto a validação humana independente permanece necessária.

V. CONCLUSÃO

Este trabalho abordou o problema de organizar e classificar incrementalmente uma base textual institucional em crescimento, reduzindo o custo de inferência por LLM e preservando auditabilidade, adaptação a novos temas e estabilidade taxonômica. Para isso, foi proposta uma metodologia que combina fundação temática formada pelos documentos históricos mais antigos, máscaras vetoriais de crimes em uma memória WNN e revisão contextual de documentos residuais por LLM.

Na rodada concluída, com 10% da base destinados à fundação temática, a memória WNN classificou diretamente 53,48% da reserva incremental. A LLM ficou restrita aos 46,52% de casos com evidência insuficiente, baixa margem ou ambiguidade entre máscaras. Contra as tags institucionais mapeadas após a decisão, a WNN obteve precisão de 85,29%, revocação de 49,91% e medida-F1 de 62,97%. Essa separação permite que documentos recorrentes sejam tratados por uma camada determinística, enquanto a interpretação mais custosa é reservada aos casos nos quais ela é necessária.

A contribuição do trabalho não se limita à classificação de uma coleção específica de notícias. A proposta organiza um ciclo auditável que transforma agrupamentos exploratórios em crimes canônicos, associa cada crime a uma máscara vetorial de evidências, registra as decisões da memória e encaminha incertezas para revisão residual. O vocabulário versionado e a política de acréscimo controlado preservam a comparabilidade das posições lexicais ao longo das atualizações.

Os resultados devem ser interpretados como diagnósticos operacionais internos. A qualidade da fundação temática, a representatividade temporal da amostra e a especificidade dos discriminadores influenciam a classificação. As tags institucionais permitem calcular métricas operacionais de precisão, revocação e medida-F1, mas não substituem uma amostra anotada independentemente por especialistas. Como trabalhos futuros, recomenda-se validar essa amostra, comparar a proposta com classificadores supervisionados e LLM aplicada a toda a base e testar o procedimento em outras coleções institucionais.

REFERÊNCIAS

- [1] F. Rangel, F. Firmino, P. M. V. Lima, and J. Oliveira, "Semi-supervised classification of social textual data using WiSARD," in *Proceedings of the 24th European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN 2016)*. Bruges, Belgium: i6doc.com, 2016, pp. 165–170.
- [2] H. C. d. C. Carneiro, "Theoretical results on a weightless neural classifier and application to computational linguistics," Tese de Doutorado, Universidade Federal do Rio de Janeiro, COPPE, Programa de Engenharia de Sistemas e Computação, Rio de Janeiro, RJ, Brasil, 2017.

- [3] A. Ratner *et al.*, “Snorkel: Rapid training data creation with weak supervision,” *arXiv preprint arXiv:1711.10160*, 2017. [Online]. Available: <https://arxiv.org/abs/1711.10160>
- [4] —, “Snorkel drybell: A case study in deploying weak supervision at industrial scale,” *arXiv preprint arXiv:1812.00417*, 2018. [Online]. Available: <https://arxiv.org/abs/1812.00417>
- [5] —, “Snorkel: Rapid training data creation with weak supervision,” *The VLDB Journal*, vol. 29, pp. 709–730, 2020.
- [6] J. A. Fries *et al.*, “Ontology-driven weak supervision for clinical entity classification in electronic health records,” *Nature Communications*, vol. 12, 2021.
- [7] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent dirichlet allocation,” *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003. [Online]. Available: <https://jmlr.org/papers/v3/blei03a.html>
- [8] M. Grootendorst, “BERTopic: Neural topic modeling with a class-based TF-IDF procedure,” *arXiv preprint arXiv:2203.05794*, 2022. [Online]. Available: <https://arxiv.org/abs/2203.05794>
- [9] L. McInnes, J. Healy, and S. Astels, “HDBSCAN: Hierarchical density based clustering,” *Journal of Open Source Software*, vol. 2, no. 11, 2017.
- [10] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using siamese BERT-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Hong Kong: Association for Computational Linguistics, 2019, pp. 3982–3992. [Online]. Available: <https://aclanthology.org/D19-1410/>
- [11] R. Smith *et al.*, “Language models in the loop: Incorporating prompting into weak supervision,” *arXiv preprint arXiv:2205.02318*, 2022. [Online]. Available: <https://arxiv.org/abs/2205.02318>
- [12] N. Guan, K. Chen, and N. Koudas, “Can large language models design accurate label functions?” *arXiv preprint arXiv:2311.00739*, 2023. [Online]. Available: <https://arxiv.org/abs/2311.00739>
- [13] C. Huang and G. He, “Text clustering as classification with LLMs,” *arXiv preprint arXiv:2410.00927*, 2024. [Online]. Available: <https://arxiv.org/abs/2410.00927>
- [14] A. D. Sosnovikov, A. D. Zemerov, and D. Y. Turdakov, “Iterative weak supervision with LLM-guided labeling function refinement,” *Proceedings of the Institute for System Programming of the RAS*, vol. 37, no. 6(2), pp. 65–76, 2025. [Online]. Available: <https://www.mathnet.ru/eng/tisp1074>
- [15] S. Shah and K. Shridhar, “Select-then-route: Taxonomy guided routing for LLMs,” in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing: Industry Track*. Suzhou, China: Association for Computational Linguistics, 2025, pp. 425–441. [Online]. Available: <https://aclanthology.org/2025.emnlp-industry.28/>
- [16] C. Xia, W. Yin, Y. Feng, and P. Yu, “Incremental few-shot text classification with multi-round new classes: Formulation, dataset and system,” in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Online: Association for Computational Linguistics, 2021, pp. 1351–1360. [Online]. Available: <https://aclanthology.org/2021.naacl-main.106/>
- [17] L. A. Tuan, S. C. Hui, and S. K. Ng, “Utilizing temporal information for taxonomy construction,” *Transactions of the Association for Computational Linguistics*, vol. 4, pp. 551–564, 2016. [Online]. Available: <https://aclanthology.org/Q16-1039/>
- [18] A. Balakrishnan, “Automated taxonomy construction using large language models: A comparative study of fine-tuning and prompt engineering,” *Information*, vol. 6, no. 11, 2025. [Online]. Available: <https://www.mdpi.com/2673-4117/6/11/283>
- [19] E. Agichtein and L. Gravano, “Snowball: Extracting relations from large plain-text collections,” in *Proceedings of the Fifth ACM International Conference on Digital Libraries*. New York, NY, USA: ACM, 2000, pp. 85–94.