

Clusterizacao semantica e classificacao hibrida de noticias sobre operacoes da Policia Federal

Projeto NT PF

8 de maio de 2026

Resumo

This paper describes a computational pipeline for transforming public news about Brazilian Federal Police operations into a structured analytical corpus. The method combines automated collection, textual extraction, hybrid classification with regular expressions and large language models, controlled summarization, semantic clustering, consensus analysis and continuous rule learning. Semantic clustering is used as an exploratory instrument, while hybrid classification produces auditable variables about crimes, modus operandi, affected sectors, actors and operational recurrence.

Resumo

Este artigo descreve uma metodologia computacional para transformar noticias publicas sobre operacoes da Policia Federal brasileira em uma base analitica estruturada. A proposta combina coleta automatizada, extracao textual, classificacao hibrida por expressoes regulares e modelos de linguagem, resumo controlado, clusterizacao semantica, consenso entre especificacoes e aprendizado continuo de regras. A estrategia separa duas finalidades: a clusterizacao semantica e usada como instrumento exploratorio para descobrir padroes no corpus; a classificacao hibrida e usada para produzir variaveis substantivas auditaveis sobre crimes, modus operandi, setor afetado, atores e ocorrencia operacional. O resumo controlado e tratado como camada complementar, nao como substituto do texto integral.

1 Introducao

Noticias institucionais sobre operacoes policiais formam um corpus rico para observar ocorrencias de crimes, modos de atuacao, territorios e formas de cooperacao estatal. Entretanto, esses textos tendem a ser heterogeneos: variam em extensao, estilo, nivel de detalhe, uso de tags, presenca de nomes de operacao e padrao narrativo. Essa heterogeneidade dificulta a construcao direta de categorias consistentes.

A metodologia proposta combina tres familias de tecnicas. Primeiro, utiliza representacoes vetoriais de texto e similaridade do cosseno para aproximar noticias semanticamente semelhantes, em linha com abordagens de embeddings e modelagem de topicos por agrupamento (Reimers and Gurevych, 2019; Grootendorst, 2022; Angelov, 2020). Segundo, aplica classificacao hibrida: regras deterministicas de alta confianca

classificam casos claros, enquanto modelos de linguagem são acionados para casos ambíguos ou não capturados pelas regras (Gilardi et al., 2023; Rytting et al., 2023; Heseltine and Clemm von Hohenberg, 2024; Tornberg, 2025). Terceiro, avalia a estabilidade dos agrupamentos por consenso entre especificações, inspirado na literatura de consenso de clusters (Monti et al., 2003).

2 Dados

O universo empírico é composto por notícias publicadas no portal público da Polícia Federal sobre operações. Cada notícia é representada como uma unidade documental. Para cada unidade, o pipeline preserva metadados objetivos e texto integral extraído em formato Markdown.

Os campos mínimos previstos são:

- identificador ou link canônico da notícia;
- título e subtítulo;
- data de publicação e, quando disponível, data de atualização;
- URL de origem;
- texto integral extraído;
- tags institucionais;
- dateline, UF e município quando identificáveis;
- nome de operação, quando explicitamente mencionado.

O pipeline também deve registrar controle de qualidade textual. Notícias vazias, incompletas, duplicadas ou sem corpo extraído suficiente devem receber flag própria, para que a análise principal consuma apenas registros válidos.

3 Pipeline metodológico

A Figura 1 apresenta o fluxo de dados da pipeline desde a extração das notícias até a classificação, clusterização e publicação dos artefatos analíticos. O desenho separa as camadas determinísticas, a camada semântica acionada por execução e a etapa exploratória de consenso.




Figura 1: Fluxo de dados da pipeline, da extração das notícias a classificação, aprendizado contínuo, clusterização e geração de artefatos.

1. Coleta da listagem paginada de notícias.
2. Extração do conteúdo principal de cada página individual.
3. Conversão do conteúdo para Markdown e padronização dos metadados.
4. Limpeza textual sem remover informação substantiva.
5. Classificação por regras regex de alta confiança.
6. Encaminhamento dos casos não cobertos ou conflitantes para LLM.
7. Geração de resumo curto, resumo estruturado, evidência textual, atores e setor afetado.
8. Construção de três representações textuais: integral, resumida e híbrida.
9. Clusterização semântica e recuperação de vizinhos por similaridade do cosseno.
10. Experimento de consenso entre especificações alternativas.
11. Aprendizado contínuo de regras regex a partir dos casos encaminhados a LLM.
12. Produção da base final e dos artefatos analíticos.

4 Preparação textual

Cada notícia é convertida para texto limpo, preservando nomes de operações, órgãos, crimes mencionados, localidades, valores, mandados e outros sinais substantivos. Elementos repetitivos de página, menus, rodapés e links irrelevantes devem ser removidos.

A geografia é tratada separadamente: termos geograficos podem ser removidos da representação semântica para evitar que clusters sejam dominados por UF ou município, mas são preservados como variáveis analíticas.

5 Classificação híbrida

A classificação final é concebida como um sistema em camadas. A primeira camada aplica expressões regulares versionadas para padrões de alta confiança. Exemplos incluem menções diretas à lavagem de dinheiro, garimpo ilegal, pornografia infantil, fraude previdenciária, descaminho, corrupção e tráfico de drogas.

Cada regra deve preservar:

- classe atribuída;
- regra acionada;
- trecho que acionou a regra;
- nível de confiança;
- versão da regra.

Casos não capturados ou com sinais conflitantes são encaminhados a uma LLM. A LLM não recebe uma tarefa aberta; ela deve escolher exclusivamente entre categorias da taxonomia, retornar JSON válido e indicar evidência textual curta. A saída estruturada inclui classe principal, classes secundárias, modus operandi, setor afetado, atores mencionados, resumo curto, resumo estruturado, confiança e flag de reprocessamento automático. Portanto, o papel da LLM no projeto não é substituir todo o classificador: ela funciona como camada semântica controlada, acionada quando a camada barata de regex não resolve o caso, e como fonte de exemplos para o aprendizado contínuo de novas regras.

6 Resumo controlado como camada complementar

O comentário metodológico que motivou esta atualização sugere que resumos curtos podem ajudar na clusterização semântica e na criação de categorias. A proposta adotada é testar essa hipótese sem abandonar o texto integral.

Assim, o pipeline constroi três representações:

Texto integral título, subtítulo e corpo normalizado. Serve para descoberta livre e exploratória.

Texto resumido título, subtítulo, resumo curto, resumo estruturado, evidência, atores e setor afetado. Serve para reduzir heterogeneidade narrativa.

Texto híbrido combina identidade canônica, crimes, modus, tags, resumo e texto integral. Serve como representação principal do painel.

Essa decisao permite comparar se o resumo melhora estabilidade e interpretabilidade ou se perde informacao substantiva relevante. A expectativa e que os dois usos sejam complementares: o texto integral favorece descoberta; o resumo favorece padronizacao.

7 Clusterizacao semantica

Cada noticia e representada em um espaco vetorial. A implementacao atual usa TF-IDF, reducao por SVD e normalizacao, mantendo similaridade do cosseno como metrica de proximidade. A metodologia tambem e compativel com embeddings neurais, como Sentence-BERT, ou modelos de topicos baseados em embeddings e agrupamento, como BERTopic e Top2Vec (Reimers and Gurevych, 2019; Grootendorst, 2022; Angelov, 2020).

A clusterizacao principal utiliza K-means em mini-lotes. O numero de clusters e escolhido por avaliacao de silhouette em uma grade de valores. Como alternativa metodologica, o experimento de consenso tambem aplica clusterizacao hierarquica e HDBSCAN sobre as representacoes integral, resumida e hibrida (Campello et al., 2013).

O HDBSCAN entra como apoio exploratorio, nao como classificacao final. Sua utilidade decorre de cinco propriedades: nao exige definir previamente o numero de clusters; permite marcar ruido e outliers; lida melhor com grupos de tamanhos diferentes; pode revelar subtemas densos dentro de categorias grandes, como corrupcao, crimes ambientais ou crimes contra criancas; e aumenta a robustez do consenso quando concorda com K-means e clusterizacao hierarquica. Por isso, o K-means permanece como cluster principal do painel, enquanto o HDBSCAN opera como diagnostico de estabilidade e descoberta de agrupamentos naturais.

8 Consenso e estabilidade

Como uma solucao unica de clusterizacao pode depender de algoritmo, parametros e representacao textual, a metodologia inclui um experimento de consenso. Para cada noticia, sao salvos os clusters obtidos em diferentes especificacoes. Em seguida, o pipeline calcula pares estaveis entre vizinhos semanticos: dois documentos formam um par estavel quando aparecem juntos em pelo menos 80% das especificacoes validas.

Essa abordagem evita gravar uma matriz completa de coocorrencia para milhares de documentos e produz um artefato interpretavel: uma lista de pares robustos. Esses pares orientam a nomeacao automatica de clusters, o aprendizado de novas regras e a construcao incremental de categorias dentro da taxonomia existente.

9 Taxonomia substantiva

A taxonomia e organizada em multiplos niveis. O primeiro nivel cobre grandes areas, como corrupcao, lavagem de dinheiro, trafico de drogas e armas, crimes ambientais, crimes financeiros, fraudes previdenciarias, crimes ciberneticos, crimes eleitorais, fronteira e outros. O segundo nivel detalha tipos especificos de crime. O terceiro nivel descreve modus operandi, como empresa de fachada, uso de laranjas, contratos simulados, notas

fiscais falsas, criptoativos, transporte aereo, transporte maritimo, servidores publicos envolvidos e documentos falsos.

Uma noticia pode receber multiplos rotulos. Portanto, a classificacao deve ser tratada como multilabel, e nao como atribuicao exclusiva de uma unica categoria.

10 Aprendizado continuo

A classificacao foi desenhada para nao depender de intervencao humana nessa etapa do processo. O ciclo de melhoria ocorre automaticamente. Primeiro, regras regex classificam os casos de alta confianca. Segundo, casos abaixo do limiar, conflitantes ou nao cobertos sao enviados para a LLM. Terceiro, a resposta da LLM e validada por schema e normalizada para a taxonomia permitida. Quarto, quando a LLM atribui rotulos com evidencia textual suficiente, o sistema tenta derivar padroes regex candidatos. Quinto, filtros automaticos removem padroes frageis, genericos, malformados ou sem evidencia lexical da classe atribuida.

As regras aprendidas sao gravadas em arquivo versionavel e entram na execucao seguinte do classificador. Dessa forma, a cobertura tende a aumentar ao longo das rodadas, enquanto a taxonomia permanece controlada. A LLM nao cria categorias livres; ela opera dentro de listas permitidas, e o aprendizado de regras e condicionado por evidencias extraidas do proprio texto.

Algoritmo 1: Reducao de custo por aprendizado continuo de regras

Entrada: Noticia em Markdown, regras regex estaticas, regras aprendidas e limiar de confianca.

Saida: Inferencia validada, fonte da classificacao e novas regras candidatas.

```
1 foreach noticia no corpus do
2   extrair metadados objetivos do Markdown;
3   aplicar o classificador regex com regras estaticas e aprendidas;
4   if a confianca do regex e maior ou igual ao limiar then
5     aceitar a inferencia regex;
6     registrar a fonte da classificacao como regex;
7     registrar custo de LLM igual a zero;
8   else
9     enviar a noticia para a LLM com schema fechado;
10    validar e normalizar a resposta com Pydantic;
11    registrar a fonte da classificacao como llm;
12    derivar regras regex candidatas a partir da inferencia e da evidencia
        textual;
13    remover regras frageis, genericas, malformadas ou sem evidencia lexical;
14    salvar as regras aprovadas no arquivo versionavel de regras aprendidas;
15 Na proxima execucao: carregar as regras aprendidas antes de chamar a LLM,
    aumentando a cobertura local por regex e reduzindo chamadas futuras ao
    modelo.
```

11 Artefatos esperados

Ao final, cada noticia deve compor uma linha na base estruturada com campos como:

Campo	Descricao
link	URL ou identificador canonico da noticia
data	data normalizada de publicacao
uf, municipio	localidade extraida ou inferida
titulo	titulo original
cluster_id	cluster exploratorio principal
cluster_canonico	agrupamento guiado por identidade padronizada
classe_principal	categoria substantiva principal
classes_secundarias	categorias adicionais
crime_investigado	crimes multilabel
modus_operandi	modos de atuacao multilabel
setor_afetado	setor ou politica publica afetada
atores_mencionados	atores explicitamente citados
resumo_curto	frase factual controlada
evidencia_textual	trecho justificativo curto
metodo_classificacao	regex, regex_rescue ou LLM
regra_acionada	regra deterministica, quando houver
confianca	confianca ou limiar aplicavel
precisa_reprocessamento	flag de ambiguidade ou conflito para nova rodada automatica

12 Resultados da execucao local

A pipeline foi reexecutada localmente em 08/05/2026 apos a incorporacao do HDBSCAN e a correcao do controle incremental por arquivo markdown. A etapa de metadados processou 8.048 arquivos markdown. Desse total, 7.884 foram resolvidos diretamente por regex e 164 exigiram chamada a LLM. Em termos operacionais, isso significa que aproximadamente 98% dos arquivos foram classificados pela camada barata e deterministica, enquanto cerca de 2% precisaram da camada semantica mais custosa.

O aprendizado continuo tambem foi acionado na execucao. Foram identificados 123 registros com sugestoes de aprendizado e 136 sugestoes de regra. A base consolidada de regras aprendidas passou a conter 18 grupos e 168 padroes. Esses numeros indicam o papel pratico da LLM no projeto: ela nao substitui o classificador principal, mas cobre casos nao resolvidos por regex e gera exemplos que podem reduzir chamadas futuras.

A etapa analitica produziu um corpus enriquecido com 8.055 noticias, apos remover 59 links duplicados do indice antes do merge. No corpus final, 7.891 noticias ficaram associadas a classificacao por regex e 164 a classificacao por LLM. A clusterizacao principal gerou 16 clusters por K-means, e a camada canonica produziu 38 grupos substantivos.

O experimento de consenso produziu 15.276 pares estaveis a partir de 9 especificacoes: K-means, hierarquico e HDBSCAN aplicados as representacoes integral, resumida e hibrida. O HDBSCAN marcou como ruido 5.662 noticias na representacao integral,

7.442 na resumida e 3.718 na híbrida. Esse comportamento confirma seu papel exploratório: ele é mais rigoroso para formar grupos densos, ajuda a identificar outliers e subtemas, mas não deve ser usado isoladamente como classificação final.

13 Discussão

A combinação de clusterização semântica e classificação híbrida equilibra descoberta e mensuração. A clusterização explora padrões sem impor categorias previamente fechadas. A classificação transforma esses padrões em variáveis auditáveis. O resumo controlado adiciona uma representação padronizada, especialmente útil quando os textos originais são heterogêneos. O aprendizado contínuo e o consenso entre especificações reduzem o risco de tratar agrupamentos instáveis ou inferências incertas como resultado substantivo.

14 Conclusão

A metodologia proposta organiza um corpus de notícias de operações da Polícia Federal em uma base estruturada, reprodutível e auditável. O ponto central é não escolher entre texto integral, resumo, regex ou LLM, mas combinar essas camadas com funções distintas. Texto integral serve à exploração; resumo controlado serve à padronização; regex oferece alta precisão em casos claros; LLM cobre ambiguidade; consenso mede estabilidade; aprendizado contínuo amplia cobertura sem intervenção humana obrigatória.

Referências

- Angelov, D. (2020). Top2vec: Distributed representations of topics. *arXiv preprint arXiv:2008.09470*.
- Campello, R. J. G. B., Moulavi, D., and Sander, J. (2013). Density-based clustering based on hierarchical density estimates. In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer.
- Gilardi, F., Alizadeh, M., and Kubli, M. (2023). Chatgpt outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*.
- Heseltine, M. and Clemm von Hohenberg, B. (2024). Large language models as a substitute for human experts in annotating political text. *Research and Politics*, 11(1).
- Monti, S., Tamayo, P., Mesirov, J., and Golub, T. (2003). Consensus clustering: A resampling-based method for class discovery and visualization of gene expression microarray data. *Machine Learning*, 52(1–2):91–118.

- Reimers, N. and Gurevych, I. (2019). Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992.
- Rytting, C. M., Sorensen, T., Argyle, L., Busby, E., Fulda, N., Gubler, J., and Wingate, D. (2023). Towards coding social science datasets with language models. *arXiv preprint arXiv:2306.02177*.
- Tornberg, P. (2025). Large language models outperform expert coders and supervised classifiers at annotating political social media messages. *Sociological Methods and Research*.