

Clusterizacao semantica e classificacao hibrida de noticias sobre operacoes da Policia Federal

Projeto NT PF

8 de maio de 2026

Resumo

Este artigo descreve uma metodologia computacional para transformar noticias publicas sobre operacoes da Policia Federal brasileira em uma base analitica estruturada. A proposta combina coleta automatizada, extracao textual, classificacao hibrida por expressoes regulares e modelos de linguagem, resumo controlado, clusterizacao semantica, consenso entre especificacoes e aprendizado continuo de regras. A estrategia separa duas finalidades: a clusterizacao semantica e usada como instrumento exploratorio para descobrir padroes no corpus; a classificacao hibrida e usada para produzir variaveis substantivas auditaveis sobre crimes, modus operandi, setor afetado, atores e recorrencia operacional. O resumo controlado e tratado como camada complementar, nao como substituto do texto integral, permitindo testar se uma representacao mais padronizada melhora a estabilidade e a interpretabilidade dos agrupamentos.

1 Introducao

Noticias institucionais sobre operacoes policiais formam um corpus rico para observar recorrencias de crimes, modos de atuacao, territorios e formas de cooperacao estatal. Entretanto, esses textos tendem a ser heterogeneos: variam em extensao, estilo, nivel de detalhe, uso de tags, presenca de nomes de operacao e padrao narrativo. Essa heterogeneidade dificulta a construcao direta de categorias consistentes.

A metodologia proposta combina tres familias de tecnicas. Primeiro, utiliza representacoes vetoriais de texto e similaridade do cosseno para aproximar noticias semanticamente semelhantes, em linha com abordagens de embeddings e modelagem de topicos por agrupamento (Reimers and Gurevych, 2019; Grootendorst, 2022; Angelov, 2020). Segundo, aplica classificacao hibrida: regras deterministicas de alta confianca classificam casos claros, enquanto modelos de linguagem sao acionados para casos ambiguos ou nao capturados pelas regras (Gilardi et al., 2023; Rytting et al., 2023; Heseltine and Clemm von

Hohenberg, 2024; Tornberg, 2025). Terceiro, avalia a estabilidade dos agrupamentos por consenso entre especificações, inspirado na literatura de consenso de clusters (Monti et al., 2003).

2 Dados

O universo empírico é composto por notícias publicadas no portal público da Polícia Federal sobre operações. Cada notícia é representada como uma unidade documental. Para cada unidade, o pipeline preserva metadados objetivos e texto integral extraído em formato Markdown.

Os campos mínimos previstos são:

- identificador ou link canônico da notícia;
- título e subtítulo;
- data de publicação e, quando disponível, data de atualização;
- URL de origem;
- texto integral extraído;
- tags institucionais;
- dateline, UF e município quando identificáveis;
- nome de operação, quando explicitamente mencionado.

O pipeline também deve registrar controle de qualidade textual. Notícias vazias, incompletas, duplicadas ou sem corpo extraído suficiente devem receber flag própria, para que a análise principal consuma apenas registros válidos.

3 Pipeline metodológico

A Figura textual abaixo resume o fluxo completo implementado ou previsto.

1. Coleta da listagem paginada de notícias.
2. Extração do conteúdo principal de cada página individual.
3. Conversão do conteúdo para Markdown e padronização dos metadados.
4. Limpeza textual sem remover informação substantiva.
5. Classificação por regras regex de alta confiança.

1. Portal da PF: listagem publica de noticias de operacoes.
2. Coleta paginada: construcao do indice estruturado.
3. Extracao individual: HTML da noticia convertido para Markdown.
4. Metadados objetivos: titulo, subtítulo, datas, tags, dateline e nome de operacao.
5. Regex de alta confianca: primeira classificacao automatica por regras versionadas.
6. Decisao automatica: aceita regex acima do limiar; caso contrario, envia para LLM.
7. LLM com schema fechado: crime, modus, resumo, evidencia, atores, setor e ambiguidade.
8. Aprendizado contínuo: inferencias da LLM sugerem regras candidatas; filtros automaticos limpam regras frageis.
9. Artefato enriquecido: JSONL/CSV com metadados, fonte da classificacao, regras e evidencias.
10. Representacoes textuais: integral, resumida e hibrida.
11. Clusterizacao e vizinhanca: TF-IDF, SVD, cosseno, K-means e vizinhos semelhantes.
12. Consenso: K-means e hierarquico sobre representacoes alternativas; pares estaveis.
13. Sidas analiticas: corpus enriquecido, clusters, clusters canonicos, series, pares e dashboard.

Figura 1: Fluxo completo da pipeline de extracao, classificacao, aprendizado contínuo e analise semantica.

6. Encaminhamento dos casos nao cobertos ou conflitantes para LLM.
7. Geracao de resumo curto, resumo estruturado, evidencia textual, atores e setor afetado.
8. Construcao de tres representacoes textuais: integral, resumida e hibrida.
9. Clusterizacao semantica e recuperacao de vizinhos por similaridade do cosseno.
10. Experimento de consenso entre especificacoes alternativas.
11. Aprendizado contínuo de regras regex a partir dos casos encaminhados a LLM.
12. Producao da base final e dos artefatos analiticos.

4 Preparacao textual

Cada noticia e convertida para texto limpo, preservando nomes de operacoes, orgaos, crimes mencionados, localidades, valores, mandados e outros sinais substantivos. Ele-

mentos repetitivos de pagina, menus, rodapes e links irrelevantes devem ser removidos. A geografia e tratada separadamente: termos geograficos podem ser removidos da representacao semantica para evitar que clusters sejam dominados por UF ou municipio, mas sao preservados como variaveis analiticas.

5 Classificacao hibrida

A classificacao final e concebida como um sistema em camadas. A primeira camada aplica expressoes regulares versionadas para padroes de alta confianca. Exemplos incluem mencoes diretas a lavagem de dinheiro, garimpo ilegal, pornografia infantil, fraude previdenciaria, descaminho, corrupcao e trafico de drogas.

Cada regra deve preservar:

- classe atribuida;
- regra acionada;
- trecho que acionou a regra;
- nivel de confianca;
- versao da regra.

Casos nao capturados ou com sinais conflitantes sao encaminhados a uma LLM. A LLM nao recebe uma tarefa aberta; ela deve escolher exclusivamente entre categorias da taxonomia, retornar JSON valido e indicar evidencia textual curta. A saida estruturada inclui classe principal, classes secundarias, modus operandi, setor afetado, atores mencionados, resumo curto, resumo estruturado, confianca e flag de reprocessamento automatico.

6 Resumo controlado como camada complementar

O comentario metodologico que motivou esta atualizacao sugere que resumos curtos podem ajudar na clusterizacao semantica e na criacao de categorias. A proposta adotada e testar essa hipotese sem abandonar o texto integral.

Assim, o pipeline constroi tres representacoes:

Texto integral titulo, subtitulo e corpo normalizado. Serve para descoberta livre e exploratoria.

Texto resumido titulo, subtitulo, resumo curto, resumo estruturado, evidencia, atores e setor afetado. Serve para reduzir heterogeneidade narrativa.

Texto híbrido combina identidade canônica, crimes, modus, tags, resumo e texto integral. Serve como representação principal do painel.

Essa decisão permite comparar se o resumo melhora estabilidade e interpretabilidade ou se perde informação substantiva relevante. A expectativa é que os dois usos sejam complementares: o texto integral favorece descoberta; o resumo favorece padronização.

7 Clusterização semântica

Cada notícia é representada em um espaço vetorial. A implementação atual usa TF-IDF, redução por SVD e normalização, mantendo similaridade do cosseno como métrica de proximidade. A metodologia também é compatível com embeddings neurais, como Sentence-BERT, ou modelos de tópicos baseados em embeddings e agrupamento, como BERTopic e Top2Vec (Reimers and Gurevych, 2019; Grootendorst, 2022; Angelov, 2020).

A clusterização principal utiliza K-means em mini-lotes. O número de clusters é escolhido por avaliação de silhueta em uma grade de valores. Como alternativa metodológica, o experimento de consenso também aplica clusterização hierárquica sobre as representações integral, resumida e híbrida. Em trabalhos futuros, HDBSCAN pode ser incorporado quando a dependência estiver disponível, especialmente para lidar com ruído e número desconhecido de grupos (Campello et al., 2013).

8 Consenso e estabilidade

Como uma solução única de clusterização pode depender de algoritmo, parâmetros e representação textual, a metodologia inclui um experimento de consenso. Para cada notícia, são salvos os clusters obtidos em diferentes especificações. Em seguida, o pipeline calcula pares estáveis entre vizinhos semânticos: dois documentos formam um par estável quando aparecem juntos em pelo menos 80% das especificações válidas.

Essa abordagem evita gravar uma matriz completa de coocorrência para milhares de documentos e produz um artefato interpretável: uma lista de pares robustos. Esses pares orientam a nomeação automática de clusters, o aprendizado de novas regras e a construção incremental de categorias dentro da taxonomia existente.

9 Taxonomia substantiva

A taxonomia é organizada em múltiplos níveis. O primeiro nível cobre grandes áreas, como corrupção, lavagem de dinheiro, tráfico de drogas e armas, crimes ambientais, crimes financeiros, fraudes previdenciárias, crimes cibernéticos, crimes eleitorais, fronteira e

outros. O segundo nível detalha tipos específicos de crime. O terceiro nível descreve modus operandi, como empresa de fachada, uso de laranjas, contratos simulados, notas fiscais falsas, criptoativos, transporte aéreo, transporte marítimo, servidores públicos envolvidos e documentos falsos.

Uma notícia pode receber múltiplos rótulos. Portanto, a classificação deve ser tratada como multilabel, e não como atribuição exclusiva de uma única categoria.

10 Aprendizado contínuo

A classificação foi desenhada para não depender de intervenção humana nessa etapa do processo. O ciclo de melhoria ocorre automaticamente. Primeiro, regras regex classificam os casos de alta confiança. Segundo, casos abaixo do limiar, conflitantes ou não cobertos são enviados para a LLM. Terceiro, a resposta da LLM é validada por schema e normalizada para a taxonomia permitida. Quarto, quando a LLM atribui rótulos com evidência textual suficiente, o sistema tenta derivar padrões regex candidatos. Quinto, filtros automáticos removem padrões frágeis, genéricos, malformados ou sem evidência lexical da classe atribuída.

As regras aprendidas são gravadas em arquivo versionável e entram na execução seguinte do classificador. Dessa forma, a cobertura tende a aumentar ao longo das rodadas, enquanto a taxonomia permanece controlada. A LLM não cria categorias livres; ela opera dentro de listas permitidas, e o aprendizado de regras é condicionado por evidências extraídas do próprio texto.

11 Artefatos esperados

Ao final, cada notícia deve compor uma linha na base estruturada com campos como:

Campo	Descrição
link	URL ou identificador canônico da notícia
data	data normalizada de publicação
uf, municipio	localidade extraída ou inferida
titulo	título original
cluster_id	cluster exploratório principal
cluster_canonico	agrupamento guiado por identidade padronizada
classe_principal	categoria substantiva principal
classes_secundarias	categorias adicionais
crime_investigado	crimes multilabel
modus_operandi	modos de atuação multilabel

Campo	Descricao
setor_afetado	setor ou politica publica afetada
atores_mencionados	atores explicitamente citados
resumo_curto	frase factual controlada
evidencia_textual	trecho justificativo curto
metodo_classificacao	regex, regex_rescue ou LLM
regra_acionada	regra deterministica, quando houver
confianca	confianca ou limiar aplicavel
precisa_reprocessamento	flag de ambiguidade ou conflito para nova rodada automatica

12 Discussao

A combinacao de clusterizacao semantica e classificacao hibrida equilibra descoberta e mensuracao. A clusterizacao explora padroes sem impor categorias previamente fechadas. A classificacao transforma esses padroes em variaveis auditaveis. O resumo controlado adiciona uma representacao padronizada, especialmente util quando os textos originais sao heterogeneos. O aprendizado continuo e o consenso entre especificacoes reduzem o risco de tratar agrupamentos instaveis ou inferencias incertas como resultado substantivo.

13 Conclusao

A metodologia proposta organiza um corpus de noticias de operacoes da Policia Federal em uma base estruturada, reproduzivel e auditavel. O ponto central e nao escolher entre texto integral, resumo, regex ou LLM, mas combinar essas camadas com funcoes distintas. Texto integral serve a exploracao; resumo controlado serve a padronizacao; regex oferece alta precisao em casos claros; LLM cobre ambiguidade; consenso mede estabilidade; aprendizado continuo amplia cobertura sem intervencao humana obrigatoria.

Referências

- Angelov, D. (2020). Top2vec: Distributed representations of topics. *arXiv preprint arXiv:2008.09470*.
- Campello, R. J. G. B., Moulavi, D., and Sander, J. (2013). Density-based clustering based on hierarchical density estimates. In *Advances in Knowledge Discovery and Data Mining*, pages 160–172. Springer.

- Gilardi, F., Alizadeh, M., and Kubli, M. (2023). Chatgpt outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences*, 120(30):e2305016120.
- Grootendorst, M. (2022). Bertopic: Neural topic modeling with a class-based tf-idf procedure. *arXiv preprint arXiv:2203.05794*.
- Heseltine, M. and Clemm von Hohenberg, B. (2024). Large language models as a substitute for human experts in annotating political text. *Research and Politics*, 11(1).
- Monti, S., Tamayo, P., Mesirov, J., and Golub, T. (2003). Consensus clustering: A resampling-based method for class discovery and visualization of gene expression microarray data. *Machine Learning*, 52(1–2):91–118.
- Reimers, N. and Gurevych, I. (2019). Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992.
- Rytting, C. M., Sorensen, T., Argyle, L., Busby, E., Fulda, N., Gubler, J., and Wingate, D. (2023). Towards coding social science datasets with language models. *arXiv preprint arXiv:2306.02177*.
- Tornberg, P. (2025). Large language models outperform expert coders and supervised classifiers at annotating political social media messages. *Sociological Methods and Research*.