

Redes Neurais sem Pessoa

Aula zero - Introdução

Prof. Diego Carvalho, D.Sc - Centro Federal de Educação Tecnológica Celso Suckow da Fonseca

1. Contexto e Motivação.
2. WiSARD e discriminadores.
3. Funcionamento do curso.
4. Conclusão.


Contexto e Motivação

- Redes Neurais sem Pesos (RNP), ou Weightless Neural Networks (WNN).
- RNP usa memória em vez de pesos ajustáveis .
- O aprendizado tende a ser rápido e a implementação é simples em hardware convencional.
- O tema conecta o reconhecimento de padrões, as representações e a computação inspirada no cérebro.

- É uma rede em que o conhecimento é armazenado em memórias, tipicamente em RAMs.
- A entrada é mapeada para um endereço de memória.
- A resposta depende do conteúdo armazenado nesse endereço.
- Em vez de ajustar pesos, o sistema grava padrões observados durante o treino.

De onde viemos

- Bledsoe & Browning (1959) – primeiros experimentos com nós de RAM
- Aleksander (1966) – formalização do nó RAM como elemento computacional
- WISARD (1981) – primeiro sistema comercial de reconhecimento sem pesos
- PLN / PRAM / GSN (1987–1991) – extensões probabilísticas
- Auto-WiSARD / ClusWiSARD (2010–) – era moderna



Redes com pesos(Perceptron, MLP)

- Aprendizado por retropropagação do erro
- Ajuste iterativo de w_i (pode levar horas/dias)
- Bilhões de parâmetros em modelos modernos
- Interpretabilidade limitada

$$y = \sigma\left(\sum_i \omega_i x_i - \theta\right)$$

Redes sem peso (WNN)

- Aprendizado por escrita direta em tabelas (RAM)
- Treinamento em uma única época
- Implementação direta em hardware VLSI
- Generaliza por distancia de Hamming

$$r = C_{\downarrow} \in \{0,1\}$$

Conceito: em WNNs, aprender = escrever na memória. Nenhum peso é ajustado.


O Neurônio Formal e o Nó RAM

Modelo McCulloch-Pitts

Primeiro modelo formal do neurônio:

$$y = \sigma\left(\sum_i \omega_i x_i - \theta\right)$$

- Entradas binarias, pesos fixos
- Função degrau θ
- Para $n = 2$: implementa apenas 14 das 16 funções booleanas
- **XOR** não é linearmente separável!



Exemplo AND: $w_1 = w_2 = 1, \theta = 1.5$

$(0, 0) \rightarrow 0 ; (0, 1) \rightarrow 0 ; (1, 0) \rightarrow 0 ; (1, 1) \rightarrow 1$


O Nó RAM: Definição e Capacidade

- No RAM com n entradas binárias: 2^n posições endereçáveis.
- Entrada: $I = (I_1, \dots, I_n)$ acessa exatamente uma posição:

$$r = C_I \in \{0, 1\}$$

- Treinamento: escrever d na posição endereçada:

$$C_I \leftarrow d \in \{0, 1\}$$



Configuração

- Nó RAM com $n = 2$ entradas
- Treinar a função **OR**: $(x1 \vee x2)$
- Entradas: todos os 4 vetores binários

Passos do treinamento

- $(0,0) = 0$, escreve $C_{00} \leftarrow 1$
- $(0,1) = 1$, escreve $C_{01} \leftarrow 1$
- $(1,0) = 1$, escreve $C_{10} \leftarrow 1$
- $(1,1) = 1$, escreve $C_{11} \leftarrow 1$

Estado Final

I1	I2	Endereço	C
0	0	00	0
0	1	01	1
1	0	10	1
1	1	11	1

Recall: apresentar $(1,0)$ acessa $C_{10} = 1$


Nota: um nó RAM memoriza,
Ele não generaliza por si só.

Discriminador e WiSARD

- *Wilkie, Stonham and Aleksander's Recognition Device* = WiSARD
- Discriminador = k nós-RAM, cada um com n entradas.
- Mapeamento fixo e aleatório da imagem $\rightarrow$ nós.
- Resposta: $r = \sum_{i=1}^k C_{|i} \in [0, k]$.
- Treino: $C_{|i} \leftarrow 1$ para todos nós, com o padrão de treino.
- Padrão ruidoso: r proporcional à similaridade com o padrão treinado.

- Um discriminador por classe.
- Classificação: $\hat{c} = \arg \max_c r_c$.
- Problema: estado $C = 0$ e **ambiguo**.

Discriminador



- Redes neurais tradicionais usam combinações ponderadas de entradas e de funções de ativação.
- Redes sem peso substituem isso por consulta e escrita em memória.
- Isso reduz a dependência de um treinamento iterativo lento.

- Um neurônio sem peso pode ser visto como uma pequena memória indexada por bits de entrada.
- Se o padrão apareceu no treino, a memória responde positivamente.
- Se não apareceu, a resposta tende a ser nula ou fraca.
- Essa ideia aparece na base histórica de modelos como WiSARD.



- WiSARD é uma arquitetura de classificação composta por discriminadores com RAMs.
- Cada discriminador representa uma classe.
- A decisão final decorre da comparação entre as respostas dos discriminadores.

- **n-tuplas (ou tuplas):** pequenos conjuntos de bits usados como endereços de memória.
- **Discriminadores:** conjuntos de tuplas que representam uma classe.
- **Sistema multidiscriminador:** compara as respostas e escolhe a classe com maior evidência.

- Imagine uma imagem binária dividida em pequenos blocos de bits.
- Cada bloco acessa uma posição de memória.
- O discriminador soma as respostas dessas memórias.
- A classe com maior soma é a mais provável.


- **DRASiW**: permite produzir exemplos prototípicos, ou “imagens mentais”, das classes aprendidas.
- **Bleaching**: reduz sobreajuste e ajuda a resolver empates na classificação.
- **Tuplas multirresolucionais**: combinam diferentes tamanhos de tuplas para equilibrar a generalização e a especificidade.
- **Bloom filters**: usa filtros de Bloom para alterar a estrutura dos RAM-neurônios e reduzir o consumo de memória.
- **Regression wisard**: muda a estrutura dos discriminadores para regressão linear.

Funcionamento de um Discriminador WiSARD





Neural module

Modified RAM discriminator




Training set



Neural module


Modified RAM discriminator

Mapping



Neural module


Modified RAM discriminator



**Training
phase**

Neural module


Modified RAM discriminator



**Training
phase**

Neural module


Modified RAM discriminator



**Training
phase**

Neural module


Modified RAM discriminator



**Training
phase**

Neural module


Modified RAM discriminator



**Training
phase**

Neural module


Modified RAM discriminator



**Training
phase**


Neural module

Modified RAM discriminator




Neural module

Modified RAM discriminator




Neural module

Modified RAM discriminator




Neural module

Modified RAM discriminator




Neural module

Modified RAM discriminator




Neural module

Modified RAM discriminator



Neural module

Modified RAM discriminator



Dúvidas?

Bibliotecas para desenvolvimento

Exemplo no terminal

Estrutura do curso

- WiSARD, DRASiW e bleaching.
- PLN, PRAM e GSN.
- GNU, MAGNUS e GRAM.
- Auto-WiSARD, ClusWiSARD e Bloom Filters.

- As primeiras aulas abordam a base conceitual e as principais arquiteturas.
- Depois, há apresentações de artigos (AA) e de trabalhos (AT) dos alunos.
 - $MF = 0.35 \times AA + 0.65 \times AT$
- A disciplina enfatiza a leitura crítica, a comparação de modelos e a aplicação prática.

- O aproveitamento do curso será contabilizado conforme a Tabela 1. Além da média final favorável, os alunos devem ter frequência igual ou superior a 75% dos encontros.

Condição	Conceito
$MF \geq 8.5$	A (Excelente – Protótipo funcional, análise bem conduzida, relatório completo e bem escrito)
$7 \leq MF < 8.5$	B (Bom – Protótipo funcional, mas com lacunas na análise ou no relatório)
$5 \leq MF < 7$	C (Satisfatório – Protótipo com limitações ou análise experimental incompleta)
$MF < 5$	D (Insuficiente – Trabalho incompleto ou sem implementação funcional)

Tabela 1: Critérios de avaliação por média final

- Redes neurais sem peso são modelos de aprendizado baseados em memória.
- Elas são úteis quando se deseja aprendizado rápido e uma estrutura simples.
- Na próxima aula, entraremos na WiSARD com mais detalhes.

Diego Carvalho
diego.carvalho@cefet-rj.br